

Desenvolvimento de uma aplicação de visão computacional para a semana do veterinário

Grupo de estudo e pesquisa CiDa da Escola de Veterinária da UFMG • Setembro de 2026

Introdução

O projeto nasceu da intenção de divulgar o grupo e convidar estudantes a participar por meio de uma experiência interativa. A solução combina detecção de pessoas, rastreamento temporário e um sorteio recreativo de áreas profissionais. A escolha do modelo decorreu da tarefa, dos recursos disponíveis e da necessidade de uma resposta visual rápida.

Ao estudar o caso, o aluno deverá conseguir explicar por que usamos pesos pré-treinados, distinguir detecção de identificação, compreender a arquitetura do YOLO11 e reconhecer que uma aplicação funcionando não equivale a um modelo formalmente validado.

O que é aprendido e o que é programado

Componente	Responsabilidade no projeto
YOLO11n	Localizar pessoas em cada quadro e produzir caixas e escores de detecção.
ByteTrack	Associar detecções ao longo do vídeo e manter IDs temporários.
Sorteio em Python	Escolher uma área profissional e vinculá-la ao ID.
OpenCV e Pillow	Capturar a câmera e apresentar vídeo, caixas e textos na TV.

A aparência não é usada para avaliar vocação ou prever carreira. O título “Preveja a sua Área de Atuação Profissional em Medicina Veterinária” é um convite lúdico, a explicação ao público deve informar que o resultado é sorteado.

Como ler o documento

O fluxograma seguinte organiza sete etapas. As seções posteriores explicam cada decisão, seus fundamentos e suas consequências. As referências numeradas sustentam os conceitos técnicos. Os resultados locais são aqueles relatados durante o desenvolvimento, sem atribuição de métricas que não foram medidas.

Fluxograma das decisões do projeto




Figura 1. Fluxo autoral do desenvolvimento. Losangos representam perguntas de decisão. Os caminhos laterais indicam alternativas ou retorno aos ajustes. A aprovação para uso prolongado ainda depende de ensaio no equipamento do evento.

1 Definir o problema antes de escolher o modelo

Traduzir uma ideia em uma tarefa observável

A ideia inicial foi “reconhecer pessoas e prever sua profissão”. Para implementá-la com rigor, foi necessário separar o objetivo de comunicação da tarefa computacional. O objetivo de comunicação é atrair visitantes. A tarefa visual é localizar pessoas no vídeo. O resultado recreativo é uma categoria sorteada, sem interpretação psicológica ou profissional.

Essa separação evita escolher uma tecnologia mais complexa do que a necessária. Uma rede treinada para reconhecer rostos seria apropriada para comparar identidades em outro tipo de sistema; nossa experiência não precisa saber nomes nem reconhecer alguém que voltou horas depois.

Requisitos que orientaram as decisões

Necessidade	Consequência técnica
Várias pessoas e visitantes ao fundo	Detectar múltiplos objetos em toda a imagem; não recortar apenas uma pequena área.
Resultado legível e estável	Associar previsões aos IDs e destacar quem estiver na região central.
Notebook Windows e câmera disponível	Começar com modelo pequeno e testar o desempenho no próprio equipamento.
TV como extensão	Separar a janela de apresentação do notebook usado pelo operador.
Operação prevista de oito horas	Limpar estados antigos, facilitar encerramento e reinício e realizar ensaio prolongado.
Finalidade educativa	Explicar o sorteio e documentar escolhas e limitações.

O que era necessário para começar

Precisávamos de câmera funcional, iluminação e enquadramento adequados, conexão com a TV, ambiente Python e pesos pré-treinados. Para a integração, foram usados Anaconda, JupyterLab, Ultralytics, OpenCV, Pillow e screeninfo. O download inicial dos pacotes e do modelo exige acesso à internet; a inferência local não depende de enviar os quadros a um servidor.

Não era necessário coletar um banco para treinamento porque a categoria pessoa já existe no modelo escolhido. Entretanto, imagens ou sessões de teste representativas continuam necessárias para avaliar o funcionamento no local. Ausência de treinamento próprio não elimina a necessidade de avaliação.

2 Escolher detecção de pessoas e interação ampla

Quatro tarefas que não são equivalentes

Tarefa	Pergunta respondida
Classificação da imagem	Existe uma pessoa nesta imagem?
Deteção	Onde estão as pessoas e quantas caixas são encontradas?
Segmentação de instâncias	Quais pixels pertencem a cada pessoa?
Identificação	Esta pessoa corresponde a uma identidade conhecida?

As caixas de detecção já fornecem a informação suficiente para nossa interface. Uma máscara de segmentação seria útil se quiséssemos substituir o fundo ou colorir silhuetas, mas acrescentaria trabalho que não era necessário para escrever a área profissional acima do participante.

Por que escolhemos o corpo

O público pode caminhar, virar de perfil ou permanecer distante. Uma detecção baseada no corpo oferece um alvo visual maior do que somente o rosto. Essa escolha não garante detecção de todos: objetos muito pequenos, corpos cortados e aglomerações continuam sendo situações difíceis.

Como a região central mudou ao longo do projeto

A primeira proposta considerava restringir a participação a uma área marcada. O objetivo foi refinado: também queríamos mostrar pessoas passando ao fundo. A solução passou a detectar na imagem inteira e usar o retângulo central apenas como área de destaque visual.

Na implementação discutida, o centro geométrico da caixa determina se o objeto está dentro do retângulo. Isso não mede distância em metros. Uma pessoa distante pode estar centralizada e receber destaque; duas ou mais pessoas podem ocupá-lo simultaneamente. Se a intenção fosse favorecer somente quem está perto, seria necessária outra regra, como tamanho relativo da caixa, com suas próprias limitações.

Informação exibida e informação retida

Para cada ID, guardamos temporariamente a área sorteada, a contagem de observações e o instante da última detecção. Não há cadastro de identidades. O contador de pessoas na tela representa detecções atuais, não o total de visitantes únicos ao longo do dia.

O aplicativo foi projetado para não gravar imagens. Células de teste que exibem fotografias no Jupyter podem, porém, manter essas imagens no arquivo do notebook quando suas saídas são salvas. Para manter o relatório sem imagens dos visitantes, é necessário limpar essas saídas antes de salvar ou compartilhar.

3 Escolher um modelo pré treinado adequado

Por que YOLO11n

YOLO significa You Only Look Once. A ideia original é estimar localização e classe de objetos por uma rede integrada em uma passagem de inferência. Trata-se de um detector de um estágio, embora contenha muitas camadas e operações. A arquitetura moderna não deve ser confundida com a grade única do primeiro YOLO [1].

O arquivo yolo11n.pt é o checkpoint de detecção da variante nano. Ela tem aproximadamente 2,6 milhões de parâmetros e foi escolhida como ponto de partida pelo custo computacional reduzido. A família também possui variantes s, m, l e x. O tamanho maior não implica melhor experiência se o atraso no vídeo ficar excessivo [2].

A escolha foi pragmática, não o resultado de um campeonato experimental. Não comparamos todos os detectores no notebook do stand. Portanto, a conclusão correta é que YOLO11n atendeu ao protótipo testado, não que seja universalmente o melhor modelo para detectar pessoas.

De onde veio a capacidade de detectar pessoas

Os pesos de detecção disponíveis foram treinados no COCO, que reúne cenas cotidianas e 80 categorias de objetos. Sua divisão de 2017 contém 118.287 imagens de treinamento e 5.000 de validação. As anotações incluem categorias e caixas; uma imagem pode conter vários objetos. A classe person corresponde ao índice 0 na configuração da Ultralytics [3].

No treinamento supervisionado, o modelo recebe imagens, estima caixas e categorias, compara essas estimativas às anotações e ajusta seus parâmetros por retropropagação. Repetições desse processo permitem aprender regularidades visuais. Os pesos não constituem um catálogo das pessoas do treinamento.

Na feira, a entrada também é uma imagem convencional contendo pessoas. Essa correspondência entre tarefa e domínio permite tentar a aplicação direta. Iluminação e enquadramento locais ainda podem ser diferentes: generalização é uma capacidade a avaliar, não uma garantia.

Treinamento e inferência

Carregar yolo11n.pt e aplicar o modelo à webcam é inferência. Não fizemos fine-tuning, que exigiria atualização dos pesos com dados próprios. As áreas profissionais não são classes aprendidas pelo YOLO. O argumento classes=[0] filtra as categorias de interesse, mas não remove as demais saídas da arquitetura nem reconfigura o treinamento.

Rodar por oito horas também não faz a rede aprender com o público. Durante a sessão, mudam os quadros e os estados do rastreador; os parâmetros aprendidos permanecem os mesmos.

3 Entender a arquitetura e o aprendizado

Dos pixels às caixas

Podemos dividir a arquitetura em backbone, neck e head. O backbone extrai características; o neck combina informações de diferentes escalas; a head produz as predições. Na configuração oficial do YOLO11, parte do neck está agrupada na seção chamada head [4].

Elemento	Conceito e função
Convoluções	Filtros aprendidos transformam padrões locais da imagem em mapas de características.
C3k2	Blocos dividem, processam e recombina características com eficiência.
SPPF	Pooling em sequência agrega contexto espacial de diferentes extensões.
C2PSA	Atenção em parte das características permite relacionar posições da representação.
Fusão multiescala	Combina mapas mais detalhados com representações de contexto amplo.
Detect	Produz estimativas de localização e escores das categorias.

A atenção do C2PSA não significa que o sistema entende a intenção de uma pessoa. Também não fornece, automaticamente, uma explicação causal da decisão. O YOLO11 continua predominantemente convolucional [5].

Como lidar com pessoas de tamanhos diferentes

Para uma entrada de 640×640 pixels, as escalas P3, P4 e P5 possuem mapas de 80×80 , 40×40 e 20×20 posições, associados a reduções de 8, 16 e 32 vezes. A combinação favorece objetos de diferentes tamanhos. Essas posições são mapas internos, não recortes independentes enviados a classificadores [4].

Objetos muito pequenos continuam difíceis porque poucos pixels podem não conter informação suficiente. Aumentar a resolução de inferência pode preservar detalhes, mas eleva o custo. Ampliar a imagem na TV depois da detecção não recupera detalhes perdidos na entrada da rede.

Como o erro orienta o aprendizado

A perda de detecção combina classificação, localização baseada em CIOU e Distribution Focal Loss, ou DFL. A classificação penaliza categorias incorretas; a localização avalia o ajuste das caixas; a DFL orienta a estimação de distribuições das distâncias às bordas. Os componentes recebem pesos no objetivo de treinamento [6].

Não devemos inventar a receita exata do checkpoint, como número de épocas ou conjunto completo de aumentações. A documentação e o código devem ser usados junto à versão instalada. YOLO11 é documentado como software pela Ultralytics; o artigo do YOLO original não descreve sua arquitetura específica [2].

4 Manter o resultado estável durante o vídeo

Detecção não é rastreamento

Imagine que uma pessoa esteja à esquerda no primeiro quadro e um pouco mais ao centro no seguinte. O detector encontra caixas nos dois momentos. Sem associação temporal, não sabemos se devem receber o mesmo resultado. O ByteTrack resolve essa etapa por acompanhamento de trajetórias e associação das detecções [7].

O algoritmo usa informações de movimento e sobreposição e inclui uma associação com detecções de menor confiança para recuperar objetos difíceis. Essa associação não é reconhecimento facial. O resultado são IDs técnicos, sujeitos a interrupções e trocas quando pessoas se cruzam ou ficam ocultas [7].

A regra do sorteio

Uma nova observação recebe um ID. O programa espera três observações desse ID e sorteia uma área se ainda não houver resultado. Nas observações seguintes, consulta o dicionário e reutiliza a área. No código apresentado, a contagem é acumulada: não exige explicitamente três quadros consecutivos.

A expressão “uma vez por participante” deve ser entendida operacionalmente como “uma vez por ID temporário”. Se alguém sair e retornar com outro ID, receberá outro sorteio. Se houver troca de IDs, a área pode passar a acompanhar outra pessoa.

Dois tempos diferentes

O dicionário remove resultados após dez segundos sem atualização. Já a tolerância do ByteTrack a ausências depende de seu buffer e da implementação. Manter a área por dez segundos não obriga o rastreador a preservar o ID pelo mesmo tempo [8].

Probabilidades das áreas

A ideia inicial propunha pesos proporcionais ao mercado. Como não foi estabelecida uma fonte compatível com as nove categorias, o código entregue começou com pesos iguais. Para pesos positivos w_i , a probabilidade da categoria i é $p_i = w_i / \sum w_j$. Com nove pesos iguais, cada área tem probabilidade $1/9$, aproximadamente 11,1%.

As categorias são clínica e cirurgia de pequenos animais; clínica e cirurgia de grandes animais; clínica de animais selvagens; tecnologia e inspeção de produtos de origem animal; produção de grandes animais; produção de pequenos animais; nutrição animal; genética e melhoramento animal; medicina veterinária preventiva.

Frequências observadas em poucos visitantes não precisam ser iguais às probabilidades. O sorteio não é uma estimativa de empregabilidade. A probabilidade da área e o escore de detecção do YOLO são grandezas independentes.

5 Integrar os componentes em uma aplicação

O processamento de cada quadro

O OpenCV captura o quadro, que é espelhado para facilitar a interação. A biblioteca prepara a entrada para a rede, incluindo redimensionamento, conversão para tensor e normalização. O letterbox pode preservar a proporção com preenchimento; `imgsz=640` não significa deformar obrigatoriamente cada imagem para um quadrado [9].

A rede produz caixas candidatas. O pós-processamento aplica o limiar de confiança e a supressão de caixas redundantes, chamada NMS. Em seguida, o rastreador associa IDs, o código consulta o sorteio e o Pillow desenha os textos com acentos. A imagem composta é exibida pelo OpenCV.

Parâmetros que precisam ser interpretados

Parâmetro	Efeito e cuidado
<code>conf = 0.35</code>	Filtra escores baixos. Reduzir pode aumentar detecções e também falsos positivos.
<code>iou = 0.50</code>	Limiar da NMS. Não é o limiar de identidade do ByteTrack.
<code>imgsz = 640</code>	Tamanho de referência da inferência. Afeta detalhe e custo.
<code>classes = [0]</code>	Seleciona pessoas entre as categorias previstas.
<code>persist = True</code>	Mantém o estado do rastreador entre quadros da mesma sequência.
<code>max_det = 20</code>	Limita as detecções retornadas; não garante detectar todas as pessoas.

IoU é a área de interseção dividida pela área de união de duas caixas. Na NMS, uma sobreposição acima do limiar pode suprimir uma caixa redundante. Em cenas densas, também pode haver perda de pessoas próximas. Um escore alto não garante uma probabilidade calibrada de acerto [9].

Há interação entre componentes: se `conf` eliminar detecções fracas antes da associação, o ByteTrack não poderá utilizá-las na sua segunda etapa. O ajuste deve considerar o sistema integrado, não um parâmetro isolado [8].

Notebook para documentar e script para operar

O notebook organiza conceitos, testes e configurações. A célula iniciada com `%%writefile` grava o script sem executá-lo. No CMD ou Anaconda Prompt, o arquivo é iniciado com o Python do ambiente `feira_vet`. Ambos os prompts podem usar exatamente o mesmo ambiente; a diferença não é o algoritmo.

A execução em processo independente facilita reinício e reduz a dependência do navegador. Ela não garante ausência de travamentos. A aplicação também precisa liberar a câmera e tratar erros de interface corretamente.

6 Testar corrigir e registrar o que foi observado

Desenvolvimento incremental

A sequência prática foi conferir as bibliotecas, listar monitores, testar a câmera, testar a detecção em um quadro e então integrar vídeo, rastreamento, textos e tela cheia. Esse encadeamento limita as causas possíveis de cada falha: uma câmera que não abre exige investigação diferente de uma caixa mal localizada.

Problema observado	Correção e aprendizado
OpenCV não abria janelas	A falha indicava ausência de suporte gráfico. Foi orientada a instalação da variante com GUI e o fechamento seguro para não encadear erros.
Argumento -f do ipykernel	O script havia sido executado no kernel. Usar %%writefile para criar o arquivo separa autoria e execução.
Janela cinza na TV e vídeo no notebook	A troca do nome interno por FEIRA_VET, sem acentos, resolveu o teste relatado. O título desenhado permaneceu em português.
Necessidade de retomar a sessão	Foi incluída a opção de reiniciar no prompt após encerramento ou exceção recuperável.

A correção do nome é evidência local de compatibilidade, não uma prova de que qualquer versão do OpenCV falha com Unicode. É adequado documentar o sintoma, a alteração e o resultado, sem generalizar além do teste.

O que conseguimos e o que ainda não demonstramos

Foi relatado funcionamento no monitor principal e, após o ajuste do identificador da janela, no monitor auxiliar. O protótipo integra captura, detecção, apresentação e operação por script. Não foram fornecidos resultados quantitativos de precisão, recall, latência, estabilidade de IDs ou uso de memória ao longo de oito horas.

A limpeza do dicionário impede que essa estrutura retenha todos os IDs antigos, mas não prova que todo o processo tenha memória constante. Rastreador, bibliotecas e drivers também possuem estados. Da mesma forma, tentar reabrir a câmera não equivale a um serviço com recuperação automática de qualquer falha.

Limitações da apresentação

Rótulos podem se sobrepor em multidões. Caixas pequenas não significam necessariamente pouca confiança. A composição atual redimensiona o vídeo para o monitor; se as proporções forem diferentes, pode haver distorção. Melhorias possíveis incluem manter a proporção com margens e ajustar posições dos textos, após observar necessidade real.

7 Avaliar antes de operar por oito horas

Definir critérios antes do ensaio

A proposta abaixo é um protocolo futuro, não um relato de validação já realizada. O grupo deve acordar critérios de aceitação antes de medir os resultados. Exemplos iniciais são vídeo com pelo menos 10 FPS na maior parte do teste, atraso visual inferior a 0,5 segundo e reinício simples pelo operador. Esses valores são metas locais sugeridas, não normas universais.

Dimensão	Como avaliar
Deteção	Em sessões combinadas, contar pessoas visíveis e erros de caixas; medir precisão e recall quando houver referência anotada.
Rastreamento	Registrar trocas de ID e fragmentações em entradas, saídas, cruzamentos e ocultações.
Experiência	Medir FPS e atraso visual; verificar leitura das áreas por quem está diante da TV.
Estabilidade	Executar até oito horas; observar memória, uso de CPU/GPU, temperatura e interrupções.
Recuperação	Testar encerramento, reinício e uma falha controlada de câmera; registrar tempo para retomar.

Precisão = verdadeiros positivos / todas as detecções consideradas. Recall = verdadeiros positivos / todas as pessoas de referência. Para uma avaliação anotada, deve-se definir como uma caixa prevista é associada à referência, por exemplo por IoU mínimo, sem contar duas previsões como dois acertos para a mesma pessoa.

A mAP resume curvas de precisão e recall com regras de localização. Ela não mede estabilidade de IDs. Métricas de rastreamento, como IDF1, avaliam outro aspecto. FPS é frequência de processamento; latência é o atraso entre o evento e sua apresentação. Um vídeo com buffer pode apresentar FPS razoável e atraso elevado.

Ensaio com condições variadas

Testar participantes próximos e distantes, uma pessoa e pequenos grupos, iluminação frontal e contraluz, movimentos e corpos parcialmente visíveis. Evitar uma conclusão baseada apenas no melhor cenário. Se houver comparação de modelos, usar as mesmas condições e separar as sessões de ajuste das sessões finais de avaliação.

Decisão de operação

Se o desempenho for insuficiente, identificar o gargalo antes de trocar o modelo: captura, inferência, desenho ou exibição. Reduzir a resolução pode melhorar velocidade e prejudicar pessoas distantes. Um modelo maior pode melhorar caixas e elevar o atraso. A escolha depende de medidas no equipamento real.

Para o evento, manter alimentação e ventilação adequadas, impedir suspensão, preparar os arquivos previamente e definir um operador. O programa foi concebido sem gravação; qualquer futura avaliação que envolva guardar imagens deve ser planejada separadamente e explicada aos participantes.

Modelos alternativos para a mesma tarefa

As alternativas abaixo poderiam fornecer caixas de pessoas, desde que usados checkpoints adequados. A comparação descreve características e hipóteses de uso; não apresenta um ranking medido no nosso notebook.

Alternativa	Características	Quando avaliar
YOLO11s ou maior	Mesma família, mais capacidade e maior custo [2].	Se houver erros relevantes e margem de processamento.
SSD com backbone leve	Detector de um estágio; prevê objetos em mapas de várias escalas [10].	Como alternativa de baixo custo, verificando desempenho do checkpoint.
Faster R CNN	Propõe regiões e depois classifica e refina as caixas [11].	Como comparação de arquitetura de dois estágios; medir a latência local.
RT DETR	Detector baseado em transformer, com predição de conjunto e inferência sem NMS convencional [12].	Se houver interesse em outra arquitetura e recursos suficientes.

Modelos diferentes para tarefas diferentes

YOLO11 também possui variantes de segmentação, pose, classificação de imagens e caixas orientadas. Cada tarefa usa um modelo apropriado: yolo11n.pt não produz máscaras ou articulações apenas por mudar o nome de uma opção. Segmentação seria útil para silhuetas; pose, para pontos corporais; nenhuma é necessária para nossa etiqueta sobre a caixa [2].

Alternativas ao rastreador

Deep SORT adiciona uma representação aprendida de aparência à associação temporal. Isso pode ajudar em algumas ambiguidades, mas exige outro componente e avaliação no domínio [13]. BoT-SORT é outra opção disponível no ecossistema Ultralytics, com recursos como compensação de movimento da câmera e reidentificação opcional [8].

Trocar o detector não resolve necessariamente uma troca de IDs. É preciso observar se a falha surgiu de uma pessoa não detectada, de caixas inadequadas ou de associação incorreta. Aparência para associação temporal também não implica cadastro nominal, embora acrescente processamento de características visuais.

Como justificar a escolha ao grupo

Escolhemos YOLO11n com ByteTrack porque havia uma categoria compatível, pesos prontos e uma implementação integrada que permitia testar rapidamente. Uma comparação científica futura deve manter o hardware e os cenários, registrar as versões e medir qualidade, latência e estabilidade. Não basta copiar números de velocidade publicados em outra GPU.

O que este projeto ensina para a pesquisa veterinária

Transferir o raciocínio para outra pergunta

Se quisermos localizar cães em fotografias, um detector treinado com essa categoria pode ser um ponto de partida. Se quisermos detectar uma alteração radiográfica, a correspondência muda: a categoria clínica e a modalidade visual não foram aprendidas simplesmente porque o COCO contém cães. Seriam necessários alvos bem definidos, dados anotados, adaptação e validação no domínio.

Antes de modelar, definir unidade de análise, padrão de referência e desfecho. Em dados veterinários, exames do mesmo animal não devem ser distribuídos indevidamente entre treino e teste. A avaliação em outro hospital ou equipamento testa generalização para mudanças de domínio. Essas exigências são distintas da demonstração recreativa que construímos.

Perguntas para discutir com os alunos

1. Se precisássemos contar visitantes únicos durante oito horas, os IDs temporários seriam suficientes? Explique os erros esperados.
2. Se o vídeo estivesse atrasado, quais componentes você investigaria antes de trocar o YOLO?
3. Por que a pessoa distante pode receber destaque central mesmo sem se aproximar?
4. Que evidência permitiria afirmar que YOLO11s é melhor que YOLO11n para o stand?
5. Qual a diferença entre a pontuação de uma detecção e a probabilidade de uma área sorteada?
6. O que seria necessário mudar para transformar a demonstração em pesquisa sobre detecção de alterações em imagens veterinárias?

Respostas que devem emergir da discussão

IDs não garantem visitantes únicos; velocidade depende de toda a cadeia; região central é uma regra geométrica; superioridade exige comparação controlada; sorteio e confiança são independentes; aplicação clínica demanda dados, referências e validação próprios. O resultado mais importante para o grupo é aprender a justificar decisões com objetivos e evidências.

Explicação curta para os visitantes

“O sistema usa uma rede neural treinada para localizar pessoas. Um rastreador acompanha cada pessoa enquanto ela aparece no vídeo. Nosso programa sorteia uma área da Medicina Veterinária e mostra o resultado. A atividade apresenta visão computacional; a área sorteada não avalia a sua vocação.”

Referências e fontes técnicas

Fontes primárias e documentação oficial consultadas em 15 de setembro de 2026. A documentação on-line pode mudar; em relatórios experimentais, registrar também a versão instalada e o checkpoint utilizado. As referências aos testes locais correspondem ao relato de desenvolvimento desta aplicação.

- [1] Redmon J et al. You Only Look Once Unified Real Time Object Detection. CVPR, 2016. [Acessar fonte](#)
- [2] Ultralytics. Documentação do YOLO11 e variantes. [Acessar fonte](#)
- [3] Ultralytics. COCO Detection Dataset. [Acessar fonte](#)
- [4] Ultralytics. Configuração oficial yolo11.yaml. [Acessar fonte](#)
- [5] Ultralytics. Implementação dos blocos da rede. [Acessar fonte](#)
- [6] Ultralytics. Implementação das funções de perda. [Acessar fonte](#)
- [7] Zhang Y et al. ByteTrack Multi Object Tracking by Associating Every Detection Box. ECCV, 2022. [Acessar fonte](#)
- [8] Ultralytics. Multi Object Tracking. [Acessar fonte](#)
- [9] Ultralytics. Model Prediction. [Acessar fonte](#)
- [10] Liu W et al. SSD Single Shot MultiBox Detector. ECCV, 2016. [Acessar fonte](#)
- [11] Ren S et al. Faster R CNN Towards Real Time Object Detection with Region Proposal Networks. NeurIPS, 2015. [Acessar fonte](#)
- [12] Zhao Y et al. DETRs Beat YOLOs on Real time Object Detection. CVPR, 2024. [Acessar fonte](#)
- [13] Wojke N et al. Simple Online and Realtime Tracking with a Deep Association Metric. ICIP, 2017. [Acessar fonte](#)